


제1장 단순회귀모형 추정 및 특이치·표본분포 분석

문항 1 SNS사용시간과 스트레스 지수 산점도(Scatter Plot) 및 OLS 회귀선

가로축에 SNS사용시간(X), 세로축에 스트레스지수(Y)를 나타낸 plotting 그래프를 그리고 OLS 회귀선(regression line)을 함께 나타내십시오.



[그림 1] SNS 연간 사용시간과 스트레스 지수 산점도 및 OLS 회귀선 (N=300)

문항 2 두 변수 간의 관계 서술

산점도 그래프를 관찰하여 X변수와 Y변수 간에 어떤 관계를 발견할 수 있는지 설명하십시오.

산점도 관찰 결과, **SNS 연간 사용시간(X)과 스트레스 지수(Y) 간 뚜렷한 양(+)의 선형 상관관계 확인**. SNS 사용량이 200~500시간인 저이용 학생 집단의 스트레스 지수는 20~50점대에 머무는 반면, 1,200시간을 초과하는 고이용 집단은 70~90점대 후반에 집중 분포함. 즉, 사용시간 증가에 따라 스트레스 지수의 조건부 기댓값 $E[Y|X]$ 가 일관되게 상승하는 경향성 관찰.

다만 주된 선형 추세선 궤적에서 현저히 이탈한 특이 관측치 다수 존재. 연간 이용시간이 1,500시간 이상임에도 스트레스 지수가 30점대에 머무는 집단(우하단)과, 300~700시간의 저이용 상태에서도 스트레스 지수가 90점에 육박하는 관측치(좌상단) 공존. 이러한 이격 관측치들의 OLS 추정선 왜곡 가능성에 따른 사후 잔차 진단 필요.

문항 3 OLS 단순회귀방정식 추정 및 통계량 해석

모형 $Y_i = \alpha + \beta X_i + u_i$ 를 OLS로 추정하고, 계수의 표준오차, t값, p값, 결정계수, F-통계량을 제시한 후 각 통계량의 의미와 영향을 설명하십시오.

구분	추정계수 (Coefficient)	표준오차 (SE)	t-통계량 (t-stat)	p-값 (p-value)	95% 신뢰구간
절편 ($\hat{\alpha}$)	27.3507	1.5862	17.2425	< 0.0001	[24.2291, 30.4723]
기울기 ($\hat{\beta}$: SNS시간)	0.037107	0.001612	23.0204	< 0.0001	[0.033935, 0.040279]
관측치 수 (N): 300 결정계수 (R^2): 0.6401 수정 R^2 : 0.6389 $F(1, 298)$: 529.94 ($p < 0.0001$) 오차 표준편차 (s_e): 11.0629					

1. 회귀계수 추정치 및 영향력 해석

- 기울기 계수 ($\hat{\beta} = 0.037107$):** SNS 연간 이용시간 1시간 증가 시 스트레스 지수 평균 0.0371점 증가. 연간 100시간 이용 증가 시 스트레스 지수 약 3.71점 상승하는 실질적 영향력 확인.
- 절편 계수 ($\hat{\alpha} = 27.3507$):** SNS 비이용 학생($X = 0$)의 기초 스트레스 지수 기댓값 $E[Y|X = 0]$ 을 의미.

2. 추정통계치별 의미 해석

- 표준오차 (SE):** 계수 추정량의 표본 변동 크기를 의미하며, $\hat{\beta}$ 표준오차가 0.001612로 매우 작아 추정 정밀도(Precision) 확보.
- t-통계량 (23.0204) 및 p-값 (< 0.0001):** 귀무가설 $H_0 : \beta = 0$ 에 대해 계수가 표본오차 대비 23배 이상 이격되어 1% 유의 수준에서 귀무가설 기각. SNS 이용과 스트레스 간 양의 선형 관계 확정.
- 결정계수 ($R^2 = 0.6401$):** 스트레스 지수 총변동(SST) 중 64.01%가 SNS 연간 사용시간 차이에 의해 설명됨.
- F-통계량 (529.94):** 모형 전체의 결합적 유의성 검정 지표로, 단순회귀의 $F = t^2$ 관계($23.0204^2 \approx 529.94$) 충족 및 모형 유효성 확인.

문항 4 시각적 특이치(Visual Outlier) 검토 및 제거 후 재추정 비교

그래프에서 시각적으로 확인한 outlier는 몇 번째 관측치들입니까? 이들을 제외하여 회귀방정식을 다시 추정하고 3번 결과와 비교하십시오.

산점도(그림 1) 주 군집선에서 현저하게 이탈하여 시각적으로 포착되는 대표적 관측치 내역:


- 우하단 음(-)의 극단치:** 학생 ID 44 (1,820시간, 36.5점), ID 192 (1,650시간, 32.0점), ID 265 (1,470시간, 28.5점), ID 95 (1,120시간, 22.0점) 등 4~5개 관측치.
- 좌상단 양(+)의 극단치:** 학생 ID 176 (310시간, 86.5점), ID 98 (680시간, 91.0점) 등.

시각적 판별의 주관성 한계 극복을 위해, 문항 5의 표준화 잔차($|e^*| > 2$) 분석으로 확정된 12개 이상치 제거 모형과 정량적 비교 분석 수행.

문항 5 체계적 잔차 분석, 표준화 잔차 및 특이치 통제

(1) 잔차 분포 그래프 (2) 잔차 표준편차 s_e (3) 표준화 오차 $e_i^* = e_i/s_e$ (4) $|e_i^*| > 2$ 관측치 규명 (5) 이상치 삭제 후 재추정 (6) 삭제 시 발생하는 문제점 고찰.

(1) 잔차($e_i = Y_i - \hat{Y}_i$) 분포 그래프 및 (2) 오차항의 표준편차 (s_e)



[그림 2] 회귀모형 잔차(e_i) 히스토그램 및 정규분포 적합 곡선 ($s_e = 11.0629$)

자유도 $N - 2 = 298$ 을 적용한 회귀오차 표준오차 산출식: $s_e = \sqrt{\frac{\sum e_i^2}{N-2}} = \sqrt{\frac{36466.86}{298}} = 11.0629$ (표본 표준편차 기준 11.0444).

(3)~(4) 표준화 잔차 및 특이치($|e_i^*| > 2$) 12개 관측치 규명

양(+)의 이상치 (예측 대비 고스트레스 6명, $e^* > +2$)

- ID 176: X=310시간, Y=86.5점 ($e^* = +4.31$)
- ID 98: X=680시간, Y=91.0점 ($e^* = +3.47$)
- ID 116: X=960시간, Y=96.5점 ($e^* = +3.03$)
- ID 249: X=1,185시간, Y=96.5점 ($e^* = +2.28$)
- ID 198: X=773시간, Y=80.3점 ($e^* = +2.19$)
- ID 13: X=1,290시간, Y=98.0점 ($e^* = +2.06$)

음(-)의 이상치 (예측 대비 저스트레스 6명, $e^* < -2$)

- ID 44: X=1,820시간, Y=36.5점 ($e^* = -5.28$)
- ID 192: X=1,650시간, Y=32.0점 ($e^* = -5.11$)
- ID 265: X=1,470시간, Y=28.5점 ($e^* = -4.83$)
- ID 95: X=1,120시간, Y=22.0점 ($e^* = -4.24$)
- ID 222: X=790시간, Y=17.5점 ($e^* = -3.54$)
- ID 80: X=420시간, Y=11.5점 ($e^* = -2.84$)

(5) 이상치 12개 삭제 후 OLS 재추정 비교

평가 지표	전체 데이터 (N=300)	이상치 12개 제외 (N=288)	비교 평가
절편 ($\hat{\alpha}$)	27.3507 (SE 1.5862)	24.8657 (SE 1.0693)	-2.4850 감소 (표준오차 32.6% 개선)
기울기 ($\hat{\beta}$)	0.037107 (SE 0.001612)	0.040249 (SE 0.001094)	+8.47% 상승 (우하단 극단치로 인한 하향 편의 교정)
t-통계량 (t_{β})	23.0204	36.7889	+13.77 증가 (추정 효율성 및 유의성 대폭 제고)
결정계수 (R^2)	0.6401	0.8255	+18.54%p 대폭 상승 (설명력 64% → 83%)
오차 표준편차 (s_e)	11.0629	6.6715	잔차 변동성 39.7% 축소 (적합도 급상승)

(6) 특이치 삭제 시 발생하는 방법론적 문제점

1. 선택 편향(Selection Bias) 및 외적 타당도 저하: 결정계수 제고 목적의 인위적 관측치 배제는 모집단 대표성 훼손 초래. 장시간 이용에도 스트레스 수준이 낮은 심리적 저항 집단 역시 분석 대상 현실의 일부임.
2. 누락변수 편향(Omitted Variable Bias) 은폐: 특이치는 단순 측정오차가 아닌 개인 회복탄력성, 대면 교우관계 등 미포함 주요 변수의 존재를 시사. 기계적 삭제 대신 다중회귀모형 확장 또는 로버스트 회귀분석 기법 적용이 방법론상 타당함.


문항 6 모집단 가정 하 50명 반복 표본추출과 중심극한정리(CLT)

300명을 모집단(PRF)으로 가정할 때: (1) $n=50$ 단일 표본추출 계수 비교 (2) 100회 반복 추출 계수 표본분포 그래프, 평균값, 정규분포 수렴 관찰 (3) 계수의 정규분포 수렴이 왜 중요한지 설명하십시오.

(1) 단일 50명 표본추출(SRF)과 모집단 참값(PRF) 비교

- 모집단 참 기울기 (β): **0.037107** (300명 전수 OLS 계수)
- 단일 표본 추정 기울기 ($\hat{\beta}_{sample}$): **0.041170** ($n = 50$)
- 비교 평가: 단일 표본 추출 시 표본오차로 인해 참값 대비 +0.004063의 편차 발생. 1회성 표본 관측치만으로는 모집단 참 인과관계 단정 불가 확인.

(2) 50명 표본 100회 반복추출 시뮬레이션 결과



[그림 3] 100회 반복추출된 표본 회귀계수($\hat{\beta}$)의 표본분포와 중심극한정리 정규곡선

모집단 참 모수 (β)	100회 표본평균 ($E[\hat{\beta}]$)	경험적 표준오차 (SE)	최소 추정값	최대 추정값
0.037107	0.037528	0.004573	0.024341	0.046550

100회 반복 추출된 표본기울기의 평균은 **0.037528**로 참 모수 0.037107과 일치하여 추정량의 **불편성(Unbiasedness)** 검증 완료. 그림 3과 같이 개별 표본계수들의 분포는 참 모수를 중심으로 좌우 대칭인 종 모양(Bell-shaped) 정규분포 형성 확인.

(3) 표본 회귀계수의 정규분포 수렴이 갖는 계량경제학적 중요성

실증 연구에서 모집단 오차항(u_i)의 실제 확률분포는 미지이며 비정규분포 형태가 빈번함. 그러나 표본 크기가 충분할 경우 **중심극한정리(Central Limit Theorem, CLT)**에 의하여 OLS 추정량 $\hat{\beta}$ 는 오차항의 원래 분포 형태와 무관하게 점근적 정규분포 (Asymptotic Normality)를 획득함:

$$\hat{\beta} \xrightarrow{d} N\left(\beta, \frac{\sigma^2}{\sum (X_i - \bar{X})^2}\right)$$

추정량의 정규성이 성립하지 않을 경우 t -검정, F -검정, 95% 신뢰구간 도출 등 계량경제학의 모든 통계적 가설검정 절차의 **수리적 정당성 상실**. 따라서 중심극한정리에 기반한 계수의 정규분포 수렴은 표본 데이터로부터 모집단의 참된 관계를 과학적으로 일반화하기 위한 필수적 이론적 기반임.

[온라인 연구과제 인터랙티브 실습실 안내]

본 분석의 300명 데이터 동적 산점도, 12개 이상치 제거 OLS 비교 및 100회 무작위 표본추출 실시간 시뮬레이션 웹 인터페이스 제공:

https://moonseeker.github.io/Saemaulseminar/doc2_econometrics/assignment1.html

