

숙제_제1장

첨부한 엑셀 파일 데이터 “SNS사용시간과스트레스”는 300명의 학생을 대상으로 조사한 SNS사용시간(X)과 스트레스 지수(Y) 데이터입니다.

1. SNS사용시간과 스트레스 지수 변수간의 관계를 시각적으로 확인해 봅시다. 가로축에 SNS사용시간, 세로축에 스트레스지수 변수를 나타낸 plotting 그래프를 그려 보십시오. 또한 그 plotting 그림에 회귀선(regression line)도 함께 나타내 보십시오.

2. 위의 그래프를 관찰하여 X변수와 Y변수 간에 어떤 관계를 발견할 수 있는지 설명하세요.

3. 회귀방정식의 모형은 다음과 같습니다: $Y_i = \alpha + \beta X_i + u_i$

즉 SNS사용이 스트레스에 미치는 영향을 알아보는 모형입니다.

위 모형을 OLS로 추정하고, 통상적인 추정통계치인 계수의 표준편차, t-value, p-value, 결정계수, F-통계량을 구하세요. 이 추정식에 의해 X(SNS사용시간)가 Y(스트레스 지수)에 미치는 영향을 설명하세요. 그리고 통상적인 추정통계치들이 무엇을 의미하는지 설명하십시오.

4. 위 2번 문제에서 시각화한 데이터를 살펴보면 극단치(outlier)들이 발견됩니다. 이러한 극단치들은 추정 결과를 왜곡할 수 있습니다. 그래프에서 시각적으로 확인한 outlier들은 몇 번째 관측치들입니까? 데이터에서 이 outlier에 해당하는 관측치는 제외하여 회귀방정식을 다시 추정해 보십시오. 그리고 3번에서 추정한 결과와 비교하여 보세요. 무엇이 어떻게 달라졌습니까?

5. 극단치를 식별하는 가장 간단한 방법은 위의 경우처럼 데이터를 시각화하여 눈에 띄는 특이 관측치가 있나 살펴보는 것입니다. 이보다 좀 더 체계적으로 극단치를 식별하는 방법은 위 3번 문제의 회귀방정식을 돌려서 각 관측치의 오차항(혹은 잔차항)들을 뽑고, 이들 개별 오차항들 중에 일정 범위를 벗어나는 오차항이 있나 살펴보는 것입니다. 이를 위해 다음의 절차를 수행하십시오.

(1)위 3번 문제에서의 회귀방정식을 추정하고 오차항(혹은 잔차항이라 부르기도 함)을 뽑아 데이터로 저장하세요. 그리고 오차항의 분포를 그래프로 나타내 보세요.

(2)오차항 데이터로 오차항의 표준편차(오차항들이 얼마나 퍼져 분포하고 있는지를 나타내는 지표)를 구해 보십시오.

(3)개별 오차를 위에서 구한 표준편차로 나누어 오차를 표준화하세요.

(4)표준화한 오차가 -2에서 +2 사이 구간을 벗어나면 그 관측치는 outlier로 판정합니다. 원자료 300개 관측치 중에서 몇 번째 관측치가 outlier인지 밝히세요,

(5)위에서 outlier로 판정된 관측치를 원래의 데이터에서 삭제하고 회귀분석을 다시 실시하세요.

(6)outlier를 제거한 데이터를 사용하면 어떤 문제가 있을지 생각해 보세요.

6. 이제 300명을 대상으로 조사한 원래의 데이터가 어떤 중학교 전체 모집단 자료라 가정합니다(즉 이 중학교 전교생이 300명입니다). 따라서 3번 문제에서 추정한 회귀 방정식은 모집단회귀방정식(PRF)이고, 추정된 계수는 모집단의 계수(이것을 “진짜 값”이라 합시다)입니다. 이제 모집단의 “진짜 값”을 표본(sample)을 통해 다음과 같이 추정하고자 합니다.

(1)원자료에서 50명의 표본을 무작위로 추출하여 X와 Y변수의 관계를 알아보는 회귀 방정식을 추정하세요. 표본을 이용하여 추정된 계수가 3번 문제에서 추정한 계수(“진짜 값”)와 동일한지 비교하세요.

(2)50명의 무작위 표본 추출을 100번 실시하여 각각 회귀방정식을 추정하십시오. 100 번의 회귀방정식에서 추정된 계수의 분포를 시각적(그래프)으로 나타내 보세요. 이 분포의 평균값(혹은 분포의 센터)은 얼마입니까? 이 분포의 모양은 정규분포와 닮아 있습니까?

(3)위에서 살펴본 표본 회귀분석의 계수들이 정규분포에 가깝다는 사실이 왜 중요합니까?