

제1강 회귀분석(regression analysis)이란?

X변수와 Y변수간의 평균적인 관계를 밝히는 기법

예) 60개 가구에 대해 소득과 소비를 조사하여 다음 표를 얻었다.


소득과 소비는 평균적으로 어떤 관계가 있는가?

소득	소비	소득	소비	소득	소비
80	55	160	102	240	137
80	60	160	107	240	145
80	65	160	110	240	155
80	70	160	116	240	165
80	75	160	118	240	175
100	65	160	125	240	189
100	70	180	110	260	150
100	74	180	115	260	152
100	80	180	120	260	175
100	85	180	130	260	178
100	88	180	135	260	180
120	79	180	140	260	185
120	84	200	120	260	191
120	90	200	136		
120	94	200	140		
120	98	200	144		
140	80	200	145		
140	93	220	135		
140	95	220	137		
140	103	220	140		
140	108	220	152		
140	113	220	157		
140	115	220	160		
		220	162		


소비는 소득의 함수, 즉 소비는 소득수준에 따라 결정된다는 이론이 있다. 이 이론이 타당한지를 회귀분석을 통해 검증할 수 있다.

위 데이터를 눈으로 훑어보아도 대강 소득이 높은 가구일수록 소비수준도 높은 경향을 확인할 수 있다. 이 관계를 시각화해 보면 편리하다.

소득과 소비의 관계를 시각화(plotting)해 보자. 제미나이로 시각화(plotting)한 결과는 다음과 같다.



X(소득)와 Y(소비)는 (+)의 상관관계를 가진다. X와 Y변수의 평균적 관계를 알아보기 위해 위의 그래프에서 평균선을 그려보자. 제미나이가 산출한 결과는 다음과 같다.



회귀방정식 $Y=17+0.6X$ 가 X와 Y의 평균적인 관계를 나타내는 식이다. 즉 소득이 10원 증가하면 소비는 평균적으로 6원 증가한다. 소득이 0일때의 기초소비(절편)은 평균적으로 17이다. 이와 같이 회귀식(regression equation)은 X와 Y의 평균적인 관계를 알아보는데 유용하다.

<제미나이 회귀방정식 추정결과>

변수 및 모형 평가지표	추정계수 / 통계량	표준오차 (std err)	t-통계량 (t)	p-value (Prob.)
절편 (const)	17	4.662	3.647	0.001
소득 (X)	0.6	0.025	23.537	0
결정계수 (R2)	0.905			
수정된 결정계수 (Adj. R2)	0.904			
F-통계량 (F-statistic)	554			2.30×10^{-31}
관측치 수 (Observations)	60			

여기서 p-value는 추정계수를 의미있다고 판정할 때 따르는 위험을 나타낸다. 다시 말해 실제로는 독립변수가 종속변수에 영향을 미치지 않는데도 영향을 미친다고(예를 들어, 소득이 10원 증가하면 소비가 6원 증가한다고) 잘 못 판정할 위험을 말한다. 따라서 p-value는 낮을수록 독립변수의 통계적 유의성이 높아진다는 것을 나타낸다.

위 예에서 p-value가 0.001이므로, 만약 소득이 100원이라면, 소비는 평균적으로 $17+0.6*(100)=77$ 원이 증가한다고 판정해도 잘 못 판정할 확률이 0.1%에 불과하다.

그런데 이것은 평균적인 관계일 뿐, 모든 가구가 그렇다는 것은 아니다. 실제 데이터를 보면 소득이 100원인 경우 소비가 65, 70, 74, 80, 85, 88로 각각 다르다. 평균적인 값 77과 실제 소비와의 차이를 오차항(error, disturbance term)이라 하고, u_i 혹은 e_i 로 표시한다. 오차는 실측치에서 회귀추정치를 뺀 값으로 산정한다. 이 예의 경우 오차항은 각각 -12, -7, -3, 3, 8, 11이다. 오차항의 평균은 0이거나 0에 매우 가깝다.

회귀방정식의 표현

회귀방정식은 보통 다음과 같은 일반식으로 표시한다. 여기서 첨자 i 는 개별

관측치를 나타내는데, 예를 들어 X_i 는 i 번째 관측치의 X 변수 값을 나타낸다.
 α 와 β 는 계수(coefficient)라 부르고, u_i 는 오차항(error term)이다.

$$Y_i = \alpha + \beta X_i + u_i$$

소득이 100인 6개 가구의 실제 소비와 추정된 소비(즉 회귀식에 의한 평균 소비), 그리고 오차항은 각각 다음과 같다.

Y_i	$\alpha + \beta X_i$	u_i
65	$17+0.6*(100)$	-12
70	$17+0.6*(100)$	-7
74	$17+0.6*(100)$	-3
80	$17+0.6*(100)$	3
85	$17+0.6*(100)$	8
88	$17+0.6*(100)$	11
평균 77	77	0

즉, (Y의 평균) $=\alpha + \beta X$

이와 같이 회귀방정식은 X 와 Y 변수가 평균적으로 어떤 관계를 가지고 있는가를 나타낸다 (X 의 값이 일정하게 주어질 때 Y 의 조건부 평균). 위 회귀방정식의 조건부 평균을 취하면(즉 Mean value 혹은 Expected value는) 다음과 같다.

$$E(Y_i|X_i) = \alpha + \beta X_i + 0$$

Geometrically, a regression line is simply the locus of the conditional means or expectations of the dependent variable for the fixed values of the explanatory variable(s)

모집단 회귀방정식(Population Regression Function)과 표본

위의 60개의 소득, 소비 자료는 어떤 작은 나라의 전체 집단 자료라 하자. 즉 이 나라의 총가구 수는 60이다. 그렇다면 앞에서 추정한 회귀방정식은 모집단

회귀방정식(PRF)이다. PRF는 모집단 전체에 대해 회귀분석을 실시한 것이다. 따라서 $Y=17+0.6X$ 는 나라 전체 가구에서 성립하는 X(소득)과 Y(소비)의 평균적인 관계라 할 수 있다.

그러나 현실적으로 모집단에 대한 자료를 얻을 수 없기 때문에(모집단이 너무 크므로 다 조사하려면 비용이 엄청남), β (모집단 계수)를 구할 수 없다.

표본 회귀방정식(Sample Regression Function)


현실에서는 모집단의 일부를 표본으로 추출해서 (즉 비용절약을 위해) 회귀방정식을 구하는데, 이를 표본 회귀방정식(SRF)이라 한다. 표본 회귀방정식에서 얻은 계수를 β (모집단 계수)와 구분해서 $\hat{\beta}$ 로 표시하자. 일반적으로, 회귀분석은 모집단 전체가 아닌 표본에 대해 적용하고, 이 회귀분석의 목적은 $\hat{\beta}$ 를 통해 β 를 추정하는 것이다.

The Method of Ordinary Least Squares (OLS): 최소 자승법

SRF를 추정하기 위해 오차항의 제곱의 합을 최소화하는 계수 $\hat{\beta}$ 를 찾는다.

즉 $Min \sum u_i^2 = \sum (Y_i - \hat{Y}_i)^2 = \sum (Y_i - \hat{\alpha} - \hat{\beta}X_i)^2$ 를 최소로 만드는 $\hat{\beta}$ 를 찾는 것이다. 최소자승법의 개념을 그래프로 나타내면 다음과 같다.

아래 그래프를 보면 각 X(소득)에 대해 일부 가구의 Y(소비)만 관찰한 것을 알 수 있다. 즉 60개 모집단 전체를 조사한 것이 아니라 일부 가구(표본 추출)만 조사했다는 것이다. 아래 그림은 이 표본 자료를 시각화(plotting)하여 오차항의 제곱의 합이 최소가 되도록 회귀선(regression line)을 그린 것이다. 이와 같이 표본 데이터에서 구한 회귀 방정식을 SRF(sample regression function)이라 한다. SRF에서 구한 추정계수는 β (모집단 계수)와 구분해서 $\hat{\beta}$ 으로 표시한다.




표본자료에 최소자승법(OLS)으로 구한 $\hat{\beta}$ 는 BLUE라고 불리는 통계적으로 바람직한 특성을 가지고 있다.

<참고: OLS vs. LAD>

OLS가 아닌 LAD(Least Absolute Deviation)방식으로도 회귀방정식을 추정할 수 있다. LAD는 오차의 제곱합을 최소화하는 것이 아니라, 오차의 절대값의 합을 최소화하는 추정방법이다. LAD는 OLS에 비해 오차가 큰 데이터(outlier, 이상치)에 영향을 덜 받는 경향이 있다.

OLS는 outlier의 오차의 제곱을 되도록 작게 만들기 위해 회귀선을 혼자 뚝 떨어져 있는 outlier 쪽으로 끌어당긴다. 즉 OLS는 outlier와 같은 극단치에 영향을 많이 받는다. OLS와는 달리 LAD는 outlier에 대한 저항성(robustness)이 훨씬 뛰어나다. 그럼에도 불구하고 OLS는 이러한 단점을 압도하는 특성들(BLUE)을 가지고 있다.


OLS와 LAD 회귀선 비교: Outlier에 대한 민감도



OLS estimator is BLUE : Gauss-Markov theorem

(1) Best : It has minimum variance in the class of all linear unbiased estimators

무수히 많은 선형 불편(unbiased) 추정량들 중에서 분산이 가장 작다. 불편 추정량들은 모두 모집단의 계수 β 를 중심으로 일정한 분포를 하고 있는데, β 에서 많이 벗어나지 않는 분포를 가진 추정량이 좋은 추정량이다. OLS로 추정된 $\hat{\beta}$ 는 다른 방법으로 추정한 추정량보다 β 를 중심으로 더 밀집되어 분포한다.



(2) Linear : A linear function of a random variable, such as the dependent variable Y

$\hat{\beta}$ 는 확률변수 Y의 선형식으로 표현되므로 식이 간단하여 다루기 쉽다.

단순회귀식에서 OLS로 추정한 추정계수는 다음과 같이 계산된다.

$$\hat{\beta} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sum_{i=1}^n (X_i - \bar{X})^2}, \text{ 여기서 } X \text{는 이미 주어진(fixed) 값이고, 변동하는}$$

변수는 Y(Y에는 확률변수인 오차항이 포함). 따라서 $\hat{\beta}$ 는 Y(확률변수)의 선형식, 다시 말해 많은 오차항들의 가중평균이다.

$\hat{\beta}$ 가 독립적인 무작위 오차항들의 가중평균이라는 것은 중심극한정리(central limit theorem)에 의해 $\hat{\beta}$ 가 정규분포를 이룬다는 매우 중요한 의미를 내포하고 있다.


(2)Unbiased : Its average or expected value, $E(\hat{\beta})$, is equal to the true value, β

$\hat{\beta}$ 는 불편 추정량이다. 즉 $E(\hat{\beta}) = \beta$ 이다.

통상 표본을 한 번만 추출하여 분석하는 현실에서 $\hat{\beta}$ 가 불편추정량이라는 사실은 매우 중요한 의미를 갖는다. 현실적으로 우리가 구한 $\hat{\beta}$ 가 운 좋게 β 와 일치할 것으로 기대할 수 없으므로, $\hat{\beta}$ 는 항상 β 보다 과대 추정되거나 과소 추정된다고 보아야 한다. 이런 상황에서 ‘불편추정량(unbiased estimator)’이라는 사실은 $\hat{\beta}$ 가 β 보다 과대평가되었을 가능성과 과소평가되었을 가능성이 균형을 이루고 있다는 것을 의미한다.

만약 $\hat{\beta}$ 가 편향(bias)이 있는 추정량이라면 체계적으로 β 보다 크게 혹은 작게 산출된다는 구조적 왜곡이 존재한다. 따라서 표본을 아무리 많이 뽑고 표본을 수없이 반복 수집해도, 공식 자체의 결함으로 인해 $\hat{\beta}$ 분포의 중심이 β 보다 항상 오른쪽(과대평가)이나 왼쪽(과소평가)으로 빗나간다.

따라서 불편성(unbiasedness)은 계수의 추정 메커니즘이 공정하다는 것을 담보한다.



통계적 추측(Statistical Inference)

표본 회귀방정식에서 추정된 $\hat{\alpha}$, $\hat{\beta}$ 는 통계적으로 얼마나 믿을 만한가?(통계적 유의성). 다시 말해, $\hat{\alpha}$, $\hat{\beta}$ 가 모집단의 α , β 와 얼마나 가까운가?

-모집단에서 일부를 표본추출(sampling) 자료를 가지고 회귀방정식을 추정하므로 추정된 $\hat{\alpha}$, $\hat{\beta}$ 계수는 통계적으로 의미가 있을 수도 있고(즉 모집단의 α , β 를 잘 반영할 수 있고), 없을 수도 있다. 왜냐하면 표본이 골고루 추출지 않았을 수도 있기 때문이다.


모집단의 오차항이 $u_i \sim N(0, \sigma^2)$ 이면 통계적 추측이 가능하다.

즉 모집단에서 주어진 X_i 에 대해 오차항의 분포가 평균이 0이고, 분산이 σ^2 (모든 i 에 대해 동일한 분산: 동분산)인 정규분포를 이룬다면 통계적 추측이 가능하다.

그러나 설령 모집단의 오차항이 정규분포를 이루지 않는다 하더라도 표본의 크기가 충분히 크면 중심극한정리에 의해 통계적 추측이 가능하다.

동분산 (Homoscedasticity)의 개념 (단순회귀분석)

모집단에서 주어진 X 값에 대해 오차항의 분포가 평균이 0이고 분산이 σ^2 인 정규분포를 이룬다.
즉, 각 X 에서 Y 의 분산이 동일($=\sigma^2$)하다.



모집단의 오차항이 $u_i \sim N(0, \sigma^2)$ 분포를 이룰 것이라는 것은 어떻게 아는가? 중심극한정리(CLT)에 의하면 독립적인 무작위 변수들이 수없이 많이 더해지면(선형결합하면) 그 합은 정규분포에 가까워진다는 사실이 알려져 있다. 모집단 회귀식의 오차항 u_i 역시 눈에 보이지 않는 수많은 미세한 요인들의 합(선형결합)으로 이루어져 있으므로, 중심극한정리에 의해 오차항 u_i 가 정규분포를 이룬다는 것을 알 수 있다.

중심극한정리(CLT: Central Limit Theorem)

“정규분포가 아닌 확률변수라도, 동일한 모집단에서 독립적으로 추출한 확률변수들을 많이 더하거나 평균을 내면, 그 합 또는 평균을 표준화한 확률변수의 분포는 표본 크기가 커질수록 정규분포에 가까워진다”

회귀분석 맥락에서 CLT는 다음의 두 측면에서 설명할 수 있다.

1. 개별 관측치 차원 (오차항 u_i 의 정규성)


개별 오차항 u_i 안에는 수많은 미세한 잡음들($e_1, e_2, e_3, \dots, e_m$)이 존재한다.

즉 $u_i = \sum_{j=1}^m e_{ij}$ 이다. 잡음의 개수 m 이 충분히 크다면, CLT에 의해 모집단의 오차항 u_i 자체가 정규분포 $u_i \sim N(0, \sigma^2)$ 를 따른다.






2. 표본 데이터 차원 (추정량 $\hat{\beta}$ 의 정규성)

모집단으로부터 추출한 표본의 크기(N)가 충분히 크다면, OLS추정량 $\hat{\beta}$ 는 N 개의 데이터들의 선형결합이므로 CLT에 의해 모집단 오차항 u_i 분포의 형태와 상관없이 $\hat{\beta}$ 는 정규분포 $\hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$ 로 수렴한다. 따라서 모집단 오차항 u_i 가 설령 정규분포가 아니라 하더라도 t-검정과 F-검정을 쓸 수 있다.

중심극한정리의 수치적 예: 균등분포에서 추출한 표본평균의 분포가 정규분포로 수렴




n 이 커질수록 표본평균의 분포는 정규분포에 가까워진다. →

	$n = 1$	$n = 2$	$n = 5$	$n = 10$	$n = 30$
표본평균 $\bar{X}$ 의 분포 (히스토그램) (10,000번 시뮬레이션)					
분포의 특징	균등분포(직사각형 모양)	삼각형 분포	종 모양에 가까워짐	정규분포와 유사	거의 정규분포

- 각 X_i 는 $U(0, 1)$ 에서 독립적으로 추출한 확률변수이다.
- 표본평균 $\bar{X}$ 는 n 이 커질수록 평균 $1/2$, 분산 $1/(12n)$ 을 갖고, 분포 모양이 정규분포에 점점 가까워진다.
- 표준화한 $Z = \frac{\bar{X} - 1/2}{\sqrt{1/(12n)}}$ 의 분포는 n 이 커질수록 표준정규분포 $N(0, 1)$ 에 수렴한다.

프롬프트: 중심극한의 정리를 수치예로 확인하고자 합니다. 0부터 1사이의 구간에서 균등분포를 이루는 확률변수가 있습니다. 이 분포에서 무작위로 두 개의 숫자를 추출하여 평균의 분포를 그래프로 나타내 주세요. 추출 횟수는 1000번입니다.




시뮬레이션 통계 요약

- 표본평균의 평균 ($\bar{X}$ 의 평균): 0.4986 (이론적 기댓값 $\mu = 0.5$)
- 표본평균의 분산: 0.0429 (이론적 분산 $\sigma^2/n = \frac{1/12}{2} \approx 0.0417$)
- 표본평균의 표준편차: 0.2070 (이론적 표준편차 ≈ 0.2041)

분포의 특징

- 원래의 모집단은 평평한 직사각형 형태(균등분포)이지만, 표본 크기가 단 $n = 2$ 인 경우에도 평균값($\bar{X}$)의 분포는 중심(0.5)에 데이터가 집중되는 **삼각분포(Triangular Distribution)** 형태를 나타냅니다.
- 표본 크기 n 이 점차 커질수록(예: $n \geq 30$) 중심극한정리에 의해 삼각 형태의 꼭짓점이 완만해지며 정규분포 곡선(Bell curve)에 더욱 가깝게 수렴합니다.

프롬프트: 중심극한의 정리를 수치예로 확인하고자 합니다. 0부터 1사이의 구간에서 균등분포를 이루는 확률변수가 있습니다. 이 분포에서 무작위로 3개 개의 숫자를 추출하여 평균의 분포를 그래프로 나타내 주세요. 추출 횟수는 1000번입니다.




시뮬레이션 통계 요약

- 표본평균의 평균 ($\bar{X}$ 의 평균): 0.4999 (이론적 기댓값 $\mu = 0.5$)
- 표본평균의 분산: 0.0289 (이론적 분산 $\sigma^2/n = \frac{1/12}{3} \approx 0.0278$)
- 표본평균의 표준편차: 0.1701 (이론적 표준편차 ≈ 0.1667)

분포의 특징

- $n = 2$ 일 때 나타났던 뾰족한 직선 형태(삼각분포)의 모서리가 $n = 3$ 에서는 2차 다항식 곡선(Bates 분포)으로 매끄럽게 다듬어지며, 정규분포 곡선의 종 모양(Bell shape)에 한층 더 가까워집니다.
- 분산 또한 $n = 2$ 일 때(≈ 0.0417)보다 줄어들어 중심값(0.5) 주변으로의 밀집도가 높아집니다.




시뮬레이션 통계 요약

- 표본평균의 평균 ($\bar{X}$ 의 평균): 0.4995 (이론적 기댓값 $\mu = 0.5$)
- 표본평균의 분산: 0.000818 (이론적 분산 $\sigma^2/n = \frac{1/12}{100} \approx 0.000833$)
- 표본평균의 표준편차: 0.0286 (이론적 표준오차 $\sqrt{1/1200} \approx 0.0289$)

분포의 특징

- 정규분포로의 완전한 수렴: 표본 크기가 $n = 100$ 에 도달함에 따라 표본평균의 히스토그램이 이론적 정규분포 $\mathcal{N}(0.5, 0.0289^2)$ 곡선과 거의 완벽하게 일치합니다.
- 표준오차의 급격한 감소: 표본 크기가 커질수록 표준편차가 $\frac{1}{\sqrt{n}}$ 에 비례하여 줄어들어, 1,000개의 모든 표본평균이 $[0.40, 0.60]$ 사이의 매우 좁은 구간 내에 밀집되어 나타납니다.



시뮬레이션 통계 요약

- 표본평균의 평균 ($\bar{X}$ 의 평균): 0.5003 (이론적 기댓값 $\mu = 0.5$)
- 표본평균의 분산: 0.000159 (이론적 분산 $\sigma^2/n = \frac{1/12}{500} \approx 0.000167$)
- 표본평균의 표준편차: 0.0126 (이론적 표준오차 $\sqrt{1/6000} \approx 0.0129$)

분포의 특징

- 극대화된 밀집도와 대칭성: $n = 100$ 일 때의 표준편차(≈ 0.0289)에 비해 분산이 대폭 줄어들어, 표본평균들이 $[0.46, 0.54]$ 라는 매우 좁은 대칭 구간 내에 집중됩니다.
- 중심극한정리 수렴: 표본의 수가 충분히 커짐에 따라 히스토그램이 정규분포 곡선 $\mathcal{N}(0.5, 0.0129^2)$ 과 높은 정밀도로 일치합니다.

$\hat{\beta}$ 를 이용한 β 에 대한 통계적 추측


만약 $u_i \sim N(0, \sigma^2)$ 이면, 표본에서 추정된 $\hat{\beta}$ 는 평균이 β 이고 분산이 $\sigma_{\hat{\beta}}^2$ 인 정규분포를 이룬다.

-즉 $\hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$, 여기서 $\sigma_{\hat{\beta}}^2 = \sigma^2 \left[\frac{\sum X_i}{n \sum (X_i - \bar{X})^2} \right]$ 이다.

(현실적으로는 모집단 분산 σ^2 을 알 수 없으므로 표본의 오차항으로 계산한 $\hat{\sigma}^2$ 을 대신 사용한다. 이 경우 표본크기(sample size)가 작으면 $\hat{\beta}$ 는 t분포를 이룬다:

*직관적 설명: 작은 표본(sample size)로 계산한 $\hat{\sigma}^2$ 은 σ^2 을 추정하는데 있어서 더 큰 불확실성이 개입한다. 따라서 정규분포보다 퍼짐의 정도가 큰 (즉, 불확실성이 큰 분포인 t분포를 이용해야 한다.)

*정규분포를 이루는 확률변수의 성격: 분산이 σ^2 인 정규분포의 경우 평균을 중심으로 $\pm \sigma$ 범위에 68%, $\pm 2\sigma$ 범위에 95%, $\pm 3\sigma$ 범위에 99.7%의 변수가 존재한다.



가설검정 Hypothesis Testing

The problem of statistical hypothesis testing may be stated simply as follows: *Is a given observation or finding compatible with some stated hypothesis or not?*

The word “compatible” means “sufficiently” close to the hypothesized value so that we do not reject the stated hypothesis.

통계적 가설검정을 간단히 표현하면 다음과 같다: 내가 가진 관측치(데이터)가 설정된 특정 가설과 양립할 수 있는가?

Stated hypothesis is called the null hypothesis and is denoted by the symbol H_0 . The null hypothesis is usually tested against an alternative hypothesis denoted by H_1 .

보통 귀무가설(null hypothesis)은 연구자가 주장하려는 내용과 반대되는 주장으로 설정한다. 연구자가 주장하려는 내용은 대립가설(alternative hypothesis)로 설정한다.

A test of significance is a procedure by which sample results are used to verify the truth or falsity of a null hypothesis. The decision to accept or reject H_0 is made on the basis of the value of the test statistic obtained from the data at hand.

회귀분석 output에 나오는 t-statistic은 표준화(standardized)된 통계치이다. 즉 평균이 0이고 분산이 1인 표준정규분포 z값의 근사값이다. sample size가 커질수록 t값은 z값에 가까워진다. t-statistic은 추정 coefficient를 std. Error로 나눈 값이다. 이는 $\hat{\beta}$ 의 분포를 평균이 0, 표준편차 1인 분포로 표준화한 t값(혹은 z값의 근사치)이다.

$$\text{곧 } z = \frac{\hat{\beta} - 0}{\sigma}$$

검정에서 표준화한 값을 쓰는 이유

만약 회귀계수 $\hat{\beta}=5$ 가 나왔다고 해보자. 이 값이 0과 비교했을 때 충분히 크고 유의미한 값인지를 판단해야 한다. 그런데 단순히 숫자 5만 보고 이것이 유의미한지 알 수 없다. 변수의 단위가 ‘억원’인지, ‘원’인지, km인지 m인지에 따라 수치의 자릿수가 완전히 달라지기 때문이다. 또한 표본의 흠여짐 정도(표준편차)가 100이라면 5는 거의 0에 가까운 미세한 값이고, 표준오차가 0.001이라면 5는 엄청나게 큰 숫자이다. 따라서 측정단위(scale)의 영향을 완전히 제거하고 “이 추정치가 표본오차의 몇 배 만큼 기준점에서 멀리 떨어져 있는가?”를 객관적 잣대로 측정하기 위해 표준화가 반드시 필요하다.

표준화는 2단계로 진행한다.

(1단계) 중심 맞추기(영점이동, centering): 추정량에서 그 분포의 중심(기대값, 참값)인 β 를 빼준다.

(2단계) 스케일(scale) 통일하기(척도변환, scaling): 중심을 0으로 맞춘 값을 그 변동의 기준 단위인 표준오차(standard error)로 나누어준다.

이러한 표준화과정을 거치면 $\hat{\beta}$ 의 분포가 평균이 0, 분산(표준편차)가 1인 표준화 분포를 얻는다.

가설검정을 할 때, 이 표준화 분포에서 t-value와 p-value를 계산하여 이용한다.


가설검정의 절차

(1) 검정할 귀무가설 H_0 과 대립가설 H_1 을 정한다.

(예: $H_0 : \beta = 0.8, H_1 : \beta \neq 0.8$)

(2) 귀무가설이 맞다는 가정하에 $\hat{\beta}$ 의 분포를 그린다. (즉 default로 귀무가설을 설정한다. 이는 연구자가 주장하려는 내용과는 상반되는 귀무가설이 맞다고 본다는 것인데, 연구자는 자신의 주장을 입증하기 위해 보수적으로 접근한다는 것이다. 일단 연구자의 주장과 상반되는 귀무가설이 맞다고 보고, 실제 추정치(데이터)가 이를 기각(reject)할 상당한 증거 혹은 이유가 있는지를 판정하는 것이다. 무죄추정의 원칙과 비슷하다. 먼저 무죄추정을 한 후, 이를 뒤엎을 충분한 증거가 있어야 유죄 판정을 내린다)


$H_0 : \beta = 0.8$ 이 true 라면



(3) 표본 데이터로 추정된 $\hat{\beta}$ 의 값이 귀무가설하의 분포에서 발생할 가능성을 판단한다. 만약 추정된 $\hat{\beta}$ 의 값이 귀무가설하에서 실제로 발생할 가능성이 희박하다면, H_0 을 기각한다.

예를 들어 그림에서 모집단 β 에 대한 추정치인 $\hat{\beta}$ 값이 0.86이 나왔다 하자. 이것이 모집단 β 가 0.8이라는 귀무가설을 옳을 만큼 충분히 강력한 증거인가를 판단하여야 한다. 즉 0.86이라는 값이 주어진 분포에서 얼마나

극단적인(발생 확률이 낮은) 값인가를 판단해야 한다. 아래 그림에서 **p-value**를 보면, 귀무가설이 옳다(즉 베타값이 0.8)할 때 $\hat{\beta}$ 가 0.86이거나 그 이상이 나올 확률은 7%이다(이 7%를 $\hat{\beta}$ 의 **p-value**라 한다). 이를 극단치라 할 수 있을까? 극단치(즉 발생확률이 낮은 값)인지 아닌지를 판정하기 위해서는 어떤 기준이 필요한데, 이 기준을 유의수준(**significance level**)이라 한다. 보통 유의수준으로 5%, 1% (드물게 10%)를 쓴다. 유의수준과 **p-value**를 비교하여 $\hat{\beta}$ 가 극단적 값인지 아닌지를 판단한다.




위 그림에서 유의수준(즉 판정 기준)이 5%라면, 7%는 극단적인 값이 아니다. 만약 유의수준이 10%라면, 7%는 극단적인 값이다. **p-value**가 극단적인 것으로 판정되면 귀무가설은 기각된다. 위 그림에서 10% 유의수준에서는 귀무가설이 기각되나, 5% 유의수준에서는 기각되지 않는다.

통계프로그램이 제시하는 **p-value** 읽는 법

일반적으로 귀무가설을 $H_0 : \beta = 0$ 으로 많이 설정한다 (즉 “X와 Y는 아무런 관계가 없다” 혹은 “추정된 계수가 0이 아닌 어떤 숫자를 가지더라도 사실상 이는 의미가 없는 숫자이다” 라고 귀무가설을 정한다)

귀무가설(Null hypothesis): “추정된 계수 값이 통계적으로 의미가 없다”

대립가설(Alternative hypothesis) “추정된 계수 값이 통계적으로 의미가 있다”



만약 p-value가 0.02라면, 귀무가설을 기각할 때(즉 대립가설을 받아들일 때) 오류의 위험이 2%이다.


만약 p-value가 0.12라면, 즉 귀무가설을 기각할 때 (즉 대립가설을 받아들일 때) 오류위험의 크기는 12%이다.

보통 추정계수의 유의성을 판단할 때 p-value값을 0.1(10%), 0.05(5%), 0.01(1%)를 기준으로 판단한다. 즉 10%, 5%, 1% 정도 이하의 위험에서는 추정계수가 의미가 있다고 판단한다.

R-squared의 의미

소득 이외에도 소비를 설명하는 변수는 많기 때문에 소득 하나만으로 소비를 100% 설명할 수는 없다. 바로 이 때문에 오차항이 발생하는 것이다.

R-squared란 소득(설명변수)가 소비(피설명변수)를 몇 %설명하는가를 나타낸다. 우리의 예에서 R-squared가 0.905이므로 소득수준이 소비액을 90%이상 설명할 수 있다는 의미이다.



$$TSS = ESS + RSS \quad (\text{Total Sum of Squares} = \text{Explained SS} + \text{Residual SS})$$

$$R^2 = ESS / TSS$$


< $\hat{\beta}$ 의 분포: 소비/소득 자료를 이용하여 확인해 보자>

-60개의 자료로 이루어진 모집단에서 30% 샘플을 추출하여 19번 회귀분석을 해 보자.

-제미나이에 다음과 같은 프롬프트를 입력했다: “원래의 데이터는 60개의 관측치로 이루어져 있습니다. 이 60개로 이루어진 모집단에서 무작위로 30% 샘플을 추출하여 회귀분석을 하여 소득(X)의 추정계수를 구합니다. 위와 같은 과정을 19번 반복하면 소득(X)에 대한 19개의 각각 다른 추정계수를 얻을 수 있습니다. 19개의 추정계수를 보여주세요”

-이와 같이 각기 다른 샘플을 19번 추출하여 각각 회귀분석한 결과, 다음과 같은 $\hat{\beta}$ 를 얻었다.

반복 회차 (Iteration)	무작위 샘플 기반 소득(X)의 추정계수
1회차	0.7317
2회차	0.5895
3회차	0.5553
4회차	0.6121
5회차	0.5943
6회차	0.6128
7회차	0.5828
8회차	0.6449
9회차	0.6333
10회차	0.62
11회차	0.6293
12회차	0.6627
13회차	0.5837
14회차	0.5619
15회차	0.6678
16회차	0.5355
17회차	0.631
18회차	0.6402
19회차	0.6454



-매 회차마다 무작위로 추출되는 데이터가 달라지기 때문에 소득(X)의 추정계수(기울기)도 조금씩 다르게 나타나며, 이는 통계학에서 말하는 표본오차(Sampling Error)와 표본분포(Sampling Distribution)의 개념을 잘 보여준다.

-모집단 계수와 비교: 앞서 전체 60개 데이터를 모두 사용했을 때의 소득(X) 추정계수는 정확히 0.6이었다.

-표본 계수의 분포: 19번 무작위 샘플링을 통해 얻은 계수들을 보면 최소 0.5355에서 최대 0.7317 사이에 분포하고 있으며, 대부분의 계수가 모집단의 진짜 값인 0.6 근처에 밀집해 있음을 확인할 수 있다.

-추출된 19개 추정계수의 평균을 내보면 약 0.6150으로, 반복 횟수를 더 늘릴수록(예: 1,000번 이상) 이 표본 계수들의 평균은 모집단의 참값인 0.6에 거의 완벽하게 수렴하게 된다. 이를 OLS 추정량의 불편이성(Unbiasedness)이라고 한다.

-또한 sample size를 더 크게 할수록 $\hat{\beta}$ (표본 베타값)의 분포는 정규분포에 가까워진다.

<참 고>

제미나이에서 CLT 시뮬레이션 예

프롬프트: CLT를 간단한 수치예를 통해 확인하고 싶습니다. 변수 X 는 100에서 200사이의 정수(즉 100, 101, 102,...,200)로 균등분포를 이루고 있습니다. 따라서 X 의 평균(모집단 평균)은 150입니다. 이제 표본 크기 20으로 X 의 표본을 무작위로 뽑아 평균을 계산합니다. 표본평균을 $\bar{X}$ 로 표기합니다. 이렇게 표본 추출을 100번 해서 $\bar{X}$ 의 분포를 그래프로 그려주세요. 표본추출 할 때마다 추출된 X , $\bar{X}$ 를 표로 정리해 함께 제시해주세요



회차	표본평균 ($\bar{X}$)	추출된 20개 표본 ($X_1 \sim X_{20}$)							
1	143.25	113, 194, 106, 108, 165, 122, 150, 181, 120, 100, 144, 145, 152, 194, 107, 154, 145, 161, 112, 192							
2	152.95	178, 162, 195, 189, 158, 144, 192, 155, 137, 125, 112, 130, 147, 194, 154, 111, 117, 171, 140, 148							
3	150.2	185, 120, 163, 166, 166, 114, 102, 149, 174, 116, 168, 119, 200, 188, 104, 109, 160, 116, 200, 185							
4	149.65	147, 173, 197, 163, 117, 129, 122, 107, 177, 111, 181, 100, 111, 131, 152, 144, 185, 196, 167, 183							
5	147.5	162, 122, 139, 120, 115, 171, 194, 152, 108, 151, 148, 197, 177, 134, 125, 176, 158, 187, 101, 113							
6	150.3	111, 194, 102, 109, 171, 138, 144, 200, 165, 135, 140, 151, 173, 151, 197, 110, 155, 139, 200, 121							
7	152.6	130, 178, 182, 180, 122, 180, 126, 146, 100, 126, 164, 138, 200, 180, 126, 100, 183, 176, 119, 196							
8	148.75	175, 125, 100, 168, 163, 160, 198, 174, 141, 147, 110, 197, 166, 113, 100, 125, 115, 121, 178, 199							
9	148.85	119, 122, 137, 143, 176, 200, 121, 152, 173, 155, 142, 197, 182, 100, 182, 106, 143, 119, 154, 154							
10	148.25	113, 183, 135, 187, 163, 107, 183, 136, 183, 162, 131, 162, 144, 158, 111, 131, 147, 132, 197, 100							
11	159.75	162, 148, 172, 188, 165, 130, 185, 137, 129, 177, 170, 188, 184, 137, 137, 168, 124, 182, 188, 124							
12	153.6	190, 150, 102, 165, 147, 183, 154, 148, 122, 103, 118, 182, 115, 137, 191, 200, 192, 136, 150, 187							
13	164.85	141, 130, 193, 144, 195, 171, 143, 199, 137, 167, 155, 186, 199, 199, 178, 136, 181, 168, 121, 154							
14	141.6	169, 145, 153, 147, 133, 100, 190, 129, 157, 191, 113, 191, 123, 100, 129, 176, 136, 106, 109, 135							
15	141.35	154, 164, 100, 111, 174, 151, 149, 124, 106, 169, 130, 154, 115, 126, 105, 190, 192, 105, 169, 139							
16	155.05	167, 176, 154, 110, 126, 152, 153, 179, 155, 150, 183, 122, 168, 161, 116, 136, 192, 123, 186, 192							
17	141.35	186, 102, 165, 106, 110, 190, 141, 133, 115, 169, 120, 171, 125, 171, 148, 111, 125, 138, 168, 133							
18	157.2	166, 102, 118, 169, 133, 175, 185, 108, 114, 188, 137, 200, 170, 181, 198, 199, 105, 146, 183, 167							
19	153.6	175, 108, 189, 148, 152, 190, 144, 125, 161, 151, 176, 106, 118, 157, 146, 193, 126, 117, 199, 191							
20	159.05	181, 132, 162, 143, 161, 122, 172, 187, 192, 178, 184, 179, 196, 107, 197, 102, 115, 133, 199, 139							
21	150.95	159, 168, 112, 193, 105, 191, 187, 108, 137, 102, 164, 127, 159, 184, 176, 178, 139, 169, 157, 104							
22	146.1	143, 182, 119, 123, 137, 150, 175, 116, 149, 199, 108, 138, 151, 157, 131, 136, 174, 170, 107, 157							
23	158.1	121, 124, 192, 184, 175, 159, 178, 127, 154, 160, 183, 182, 140, 171, 156, 138, 170, 137, 111, 200							
24	153.7	155, 124, 108, 186, 140, 188, 193, 199, 149, 166, 183, 158, 147, 128, 175, 112, 171, 125, 121, 146							
25	152.85	101, 146, 165, 191, 185, 125, 182, 173, 178, 181, 172, 150, 128, 119, 131, 173, 125, 118, 130, 184							
26	152.4	121, 103, 188, 150, 136, 195, 189, 157, 151, 186, 187, 197, 123, 113, 166, 124, 170, 153, 119, 120							
27	151.4	198, 113, 190, 122, 107, 149, 166, 200, 172, 118, 101, 142, 158, 150, 124, 132, 179, 158, 171, 178							
28	160.55	181, 186, 102, 106, 179, 160, 132, 174, 171, 192, 168, 188, 173, 194, 111, 187, 140, 134, 160, 173							
29	143	125, 185, 185, 179, 165, 129, 123, 104, 114, 169, 173, 163, 170, 117, 105, 101, 110, 116, 140, 187							
30	156.5	193, 142, 115, 124, 179, 154, 167, 164, 111, 188, 107, 173, 175, 145, 193, 197, 200, 174, 103, 126							

31~100회차 생략

표본평균 구간	중앙값	빈도수(Co	비율(%)
126.0 ~ 128.9	127.5	0	0.00%
129.0 ~ 131.9	130.5	0	0.00%
132.0 ~ 134.9	133.5	1	1.00%
135.0 ~ 137.9	136.5	3	3.00%
138.0 ~ 140.9	139.5	3	3.00%
141.0 ~ 143.9	142.5	10	10.00%
144.0 ~ 146.9	145.5	15	15.00%
147.0 ~ 149.9	148.5	17	17.00%
150.0 ~ 152.9	151.5	20	20.00%
153.0 ~ 155.9	154.5	11	11.00%
156.0 ~ 158.9	157.5	9	9.00%
159.0 ~ 161.9	160.5	8	8.00%
162.0 ~ 164.9	163.5	2	2.00%
165.0 ~ 167.9	166.5	0	0.00%
168.0 ~ 170.9	169.5	1	1.00%
171.0 ~ 173.9	172.5	0	0.00%