

STUDY GUIDE

『제1강 회귀분석이란?』

완전 해설서

통계 지식이 없어도 따라올 수 있도록
교재의 순서를 그대로 따라가며 풀어쓴 보충 자료

강의자료 1-23쪽 대응 · 모든 수식 $\LaTeX$ 조판

용어사전 및 한 장 요약 포함 · 참고문헌 APA 형식

0. 먼저, 이 강의 전체가 하려는 말 한 문장

“ X 가 변할 때 Y 는 평균적으로 얼마나 변하는가”를 숫자 하나로 뽑아내고, 그 숫자를 어느 정도 믿어도 되는지 판단하는 방법.

교재 1쪽부터 23쪽까지 나오는 모든 수식·그래프·정리는 이 한 문장을 위한 도구입니다. 길을 잃을 때마다 이 문장으로 돌아오세요. 크게 보면 강의는 두 덩어리입니다.

덩어리	다루는 질문	교재 위치
① 추정(estimation)	관계를 나타내는 숫자를 어떻게 뽑아내나?	1-7쪽 (회귀식, OLS, BLUE)
② 추론(inference)	그 숫자를 믿어도 되나?	8-19쪽 (정규분포, CLT, 가설검정, p 값, R^2)

②가 유독 어렵게 느껴지는 이유는 개념이 어려워서가 아니라, “내가 가진 데이터는 전 국민이 아니라 그중 일부일 뿐”이라는 사실 하나에서 파생된 이야기가 계속 이어지기 때문입니다. 이 사실만 붙잡고 있으면 뒷부분은 전부 연결됩니다.

1. “평균적인 관계”란 무슨 뜻인가 (교재 1-2쪽)

핵심

교재의 60개 가구 데이터를 보면, 소득이 똑같이 100원인 가구가 6곳인데 소비는 65, 70, 74, 80, 85, 88로 제각각입니다. 여기서 중요한 깨달음이 하나 있습니다.

소득 100원인 가구의 소비는 하나의 값이 아니라 값들의 무리(분포)다. 회귀분석은 그 무리 전체를 맞히려는 게 아니라, 그 무리의 중심(평균)을 맞히려는 것이다.

소득 100원 가구 6곳의 소비 평균을 실제로 계산해 보면

$$\frac{65 + 70 + 74 + 80 + 85 + 88}{6} = \frac{462}{6} = 77$$

이고, 회귀식 $Y = 17 + 0.6X$ 에 $X = 100$ 을 넣으면 $17 + 0.6(100) = 77$. 정확히 일치합니다.

이게 교재 4쪽에 나오는 어려운 문장의 정체입니다.

Geometrically, a regression line is simply the locus of the conditional means of the dependent variable for the fixed values of the explanatory variable.

→ 회귀선이란, X 를 특정 값으로 고정했을 때 Y 의 평균값들을 이어놓은 선일 뿐이다.

“조건부 평균(conditional mean)”이라는 말도 마찬가지입니다. “조건부”는 “...인 경우에 한정해서”라는 뜻입니다.

- 그냥 평균: $E(Y)$ → 60가구 전체 소비의 평균
- 조건부 평균: $E(Y | X = 100)$ → 소득이 100원인 가구만 골라서 낸 소비의 평균

회귀선 위의 점 하나하나가 바로 이 조건부 평균이며, 회귀방정식을 조건부 평균으로 쓰면 다음과 같습니다.

$$E(Y | X_i) = \alpha + \beta X_i$$

산점도 읽는 법 (2쪽 그래프)

2쪽의 첫 그래프에서 점들이 **세로로 줄지어 서 있는** 모습에 주목하세요. 소득이 80, 100, 120처럼 딱딱 떨어지는 값들만 있어서 그렇습니다. 그 세로줄 하나하나가 “소득이 X 일 때 Y 의 분포”이고, 회귀선은 **각 세로줄의 무게중심을 통과하는 선**입니다. 이 이미지를 머리에 넣어두면 나중에 9쪽 등분산 그림이 훨씬 쉬워집니다.

2. 회귀식 $Y = 17 + 0.6X$ 해석하기 (교재 3쪽)

$$Y = \underbrace{17}_{\text{절편}} + \underbrace{0.6}_{\text{기울기}} X$$

기호	이름	이 예에서의 의미
17	절편(intercept), α	소득이 0일 때의 평균 소비 = 기초소비
0.6	기울기(slope), β	소득이 1원 늘 때 소비가 평균 0.6원 는다

기울기가 회귀분석의 주인공입니다. 절편은 대개 조연입니다. 경제학에서 이 0.6은 **한계소비성향(MPC)** 이라는 이름을 가지고 있습니다. 소득이 10원 늘면 소비는 6원 늘고 4원은 저축된다는 뜻이죠.

반드시 붙여야 하는 단서: “평균적으로”

“소득이 10원 늘면 소비가 6원 는다”는 말은 **위험한 축약**입니다. 정확히는 소득이 10원 더 많은 **가구들의 평균 소비**가 6원 더 높다는 뜻입니다. 특정 한 가구가 소득이 10원 늘었을 때 소비를 정확히 6원 늘린다는 보장은 없습니다. 실제로 소득 100원 가구의 소비는 65부터 88까지 흩어져 있었죠. 회귀분석은 **개인을 맞히는 도구가 아니라 평균을 맞히는 도구**입니다.

3. 오차항: “빗나간 만큼” (교재 3-4쪽)

$$u_i = \underbrace{Y_i}_{\text{실제값}} - \underbrace{\hat{Y}_i}_{\text{예측값}}$$

소득 100원 가구 6곳을 직접 계산해 봅시다. 예측값은 모두 $\hat{Y} = 77$ 입니다.

실제 소비 Y_i	예측 소비 $\hat{Y}_i$	오차 $u_i = Y_i - \hat{Y}_i$
65	77	-12
70	77	-7
74	77	-3
80	77	+3

실제 소비 Y_i	예측 소비 $\hat{Y}_i$	오차 $u_i = Y_i - \hat{Y}_i$
85	77	+8
88	77	+11
평균 77	평균 77	합계 0 / 평균 0

교재가 “오차항의 평균은 0이거나 0에 매우 가깝다”고 한 게 이것입니다. 즉 $\sum \hat{u}_i = 0$ 입니다. 우연이 아닙니다. 회귀선을 평균을 지나도록 그었으니, 위로 빗나간 양과 아래로 빗나간 양이 상쇄되는 게 당연합니다.

오차항은 왜 생기나

소비를 결정하는 요인은 소득 말고도 많습니다. 가족 수, 나이, 건강, 소비 성향, 그날의 기분. 이 **미처 넣지 못한 모든 요인과 순수한 우연**이 뭉쳐 있는 자루가 오차항입니다. 이 관점은 나중에 10쪽 CLT 설명에서 결정적으로 쓰이니 기억해 두세요.

표기법 정리 (여기서 많이 헤맬니다)

기호	읽는 법	뜻
Y_i	와이 아이	실제로 관측된 값
$\hat{Y}_i$	와이 햇	회귀선이 예측한 값 (추정치)
α, β	알파, 베타	모집단의 진짜 계수 (신만 아는 값)
$\hat{\alpha}, \hat{\beta}$	알파햇, 베타햇	표본에서 계산한 추정치 (내가 아는 값)
u_i	유 아이	오차항
아래첨자 i	아이	i 번째 가구. X_5 는 5번째 가구의 소득

모자(^)가 씌워져 있으면 “내가 데이터로 계산해서 추측한 값” 이라고 읽으면 거의 틀리지 않습니다.

$$Y_i = \alpha + \beta X_i + u_i \quad (\text{세상의 진짜 구조: 모집단})$$

$$\hat{Y}_i = \hat{\alpha} + \hat{\beta} X_i \quad (\text{내가 데이터로 그린 선: 표본})$$

4. 모집단(PRF) vs 표본(SRF) (교재 4-5쪽)

이 강의에서 가장 중요한 구분입니다.

- **모집단(population)**: 알고 싶은 대상 전체. 예) 대한민국 모든 가구
- **표본(sample)**: 실제로 조사한 일부. 예) 무작위로 뽑은 1,000가구

전 국민을 다 조사하면 진짜 β 를 알 수 있지만, 비용과 시간 때문에 불가능합니다. 그래서 일부만 뽑아 $\hat{\beta}$ 를 구하고, 이 $\hat{\beta}$ 로 진짜 β 를 짐작한다는 게 회귀분석의 실체입니다.

	PRF (모집단 회귀함수)	SRF (표본 회귀함수)
대상	전체	일부
식	$Y_i = \alpha + \beta X_i + u_i$	$\hat{Y}_i = \hat{\alpha} + \hat{\beta} X_i$
계수	α, β (참값)	$\hat{\alpha}, \hat{\beta}$ (추정치)
알 수 있나?	불가능	계산 가능
역할	맞혀야 할 정답	정답에 대한 추측

교재의 설정이 특이한 이유

교재는 “60가구가 나라 전체”라고 가정합니다. 현실에는 없는 설정이죠. 왜 이런 가짜 설정을 할까요?

정답을 미리 알고 있어야, 추측이 얼마나 잘 맞는지 채점할 수 있기 때문입니다.

교재는 $\beta = 0.6$ 이 정답이라고 못 박아 놓고, 20-21쪽에서 표본을 19번 뽑아 $\hat{\beta}$ 가 얼마나 0.6 근처에 모이는지 채점해 보입니다. 사격장에서 과녁 중심을 미리 표시해 놓고 총알 자국을 보는 것과 같습니다.

시험 단골 질문: “회귀분석의 목적은?” → “표본에서 구한 $\hat{\beta}$ 로, 알 수 없는 모집단의 β 를 추정하는 것”

5. OLS(최소자승법): 선을 긋는 방법 (교재 5-6쪽)

점들이 흩어져 있을 때 선을 그을 방법은 무한히 많습니다. 어떤 선이 “가장 좋은” 선일까요? OLS의 답은 오차를 제공해서 다 더한 값이 가장 작아지는 선입니다.

$$\min_{\hat{\alpha}, \hat{\beta}} \sum_{i=1}^n \hat{u}_i^2 = \sum_{i=1}^n (Y_i - \hat{Y}_i)^2 = \sum_{i=1}^n (Y_i - \hat{\alpha} - \hat{\beta} X_i)^2$$

왜 그냥 더하지 않고 제곱을 하나?

1. 그냥 더하면 안 되는 이유: 앞에서 봤듯 $\sum \hat{u}_i = 0$ 입니다. 아무 선이나 그어도 상쇄되어 0이 나오니 좋고 나쁨을 구별할 수 없습니다.
2. 부호를 없애야 한다: 방법은 두 가지. 절댓값 $\sum |\hat{u}_i|$ (LAD)과 제곱 $\sum \hat{u}_i^2$ (OLS).
3. 제곱을 택한 이유: 제곱은 미분이 매끄러워 계산으로 딱 떨어지는 공식이 나오고, 크게 빗나간 점에 더 큰 벌점을 줍니다.

OLS vs LAD (교재 6쪽 참고 박스)

	OLS (최소제곱법)	LAD (최소절대편차법)
최소화 대상	$\sum \hat{u}_i^2$	$\sum \hat{u}_i $
이상치(outlier) 반응	민감 → 선이 끌려감	둔감 → 잘 안 끌려감
장점	공식이 깔끔, 통계 이론이 풍부	이상치에 강건(robust)

제곱하면 왜 이상치에 끌려가나? 10만큼 빗나가면 벌점이 $10^2 = 100$, 20만큼 빗나가면 $20^2 = 400$ 입니다. 벌점이 제곱으로 커지니, 혼자 뚝 떨어진 점 하나의 벌점을 줄이려고 선 전체가 그쪽으로 기울입니다. 6쪽 그래프에서 점선(OLS)이 위로 끌려간 모습이 이것입니다. 그럼에도 OLS를 쓰는 이유가 바로 다음 절의 BLUE입니다.

6. BLUE와 가우스-마르코프 정리 (교재 6-8쪽)

BLUE = Best Linear Unbiased Estimator (최우수 선형 불편 추정량)

앞 글자를 하나씩 떼어 보면 어렵지 않습니다. 순서는 $U \rightarrow L \rightarrow B$ 로 읽는 게 이해하기 쉽습니다.

U – Unbiased (불편, 치우침 없음)

$$E(\hat{\beta}) = \beta$$

추정치를 수없이 반복해 평균 내면 참값이 된다는 뜻입니다.

“불편”은 “편하지 않다”가 아니라 “**편(치우칠 편)이 없다**”는 뜻입니다. 한자를 알면 헛갈리지 않습니다.

과녁 비유: 총을 100발 쏘면 탄착점은 흩어지지만, 그 **평균 위치가 정확히 과녁 중심**이면 불편입니다. 개별 총알이 중심을 맞힌다는 뜻이 아닙니다. 이걸 눈으로 확인시켜 주는 게 교재 20-21쪽의 19번 반복 실험입니다.

L – Linear (선형)

$\hat{\beta}$ 를 Y 들의 가중합으로 쓸 수 있다는 뜻입니다.

$$\hat{\beta} = \sum_{i=1}^n w_i Y_i, \quad \text{여기서 } w_i = \frac{X_i - \bar{X}}{\sum (X_i - \bar{X})^2}$$

실용적 의미는 두 가지입니다.

- 계산이 단순하다.
- Y 가 정규분포면 그것들의 가중합인 $\hat{\beta}$ 도 자동으로 정규분포가 된다. → 뒤의 t 검정이 가능해지는 근거

교재에 “ X 는 이미 주어진(fixed) 값이고 변동하는 변수는 Y ”라는 말이 나옵니다. 소득 X 는 조사 설계상 고정해 놓고, 그 안에서 소비 Y 가 우연히 흔들린다고 보는 관점입니다.

B – Best (최우수 = 분산이 가장 작음)

불편인 추정 방법은 OLS 말고도 많습니다. 그중 **탄착군이 가장 촘촘한 것**이 OLS입니다. 즉 모든 선형 불편 추정량 $\tilde{\beta}$ 에 대해

$$\text{Var}(\hat{\beta}_{OLS}) \leq \text{Var}(\tilde{\beta})$$

가 성립합니다. 7쪽 그래프의 세 개 종 모양 곡선이 이 이야기입니다. 셋 다 중심은 $\beta = 2.0$ 으로 같지만(전부 불편), **OLS 곡선이 가장 뽕족하고 좁습니다**. 좁다는 건 한 번 뽑은 표본으로 계산한 $\hat{\beta}$ 가 참값에서 크게 벗어날 위험이 작다는 뜻입니다.

정리: 불편 = 평균적으로 정확하다(정확성), Best = 흔들림이 적다(정밀성). 둘 다 갖춘 게 OLS.

7. “통계적 추측”이 필요한 이유 (교재 8-9쪽)

여기서부터 강의 후반부가 시작됩니다. 문제의식은 딱 하나입니다.

$\hat{\beta} = 0.6$ 이 나왔다. 그런데 이건 **어쩌다 뽑힌 표본** 하나에서 나온 값이다. 다른 사람이 다른 표본을 뽑으면 0.58이나 0.64가 나올 것이다. 그렇다면 진짜 β 는 대체 어디쯤 있는가? $\beta = 0$ 일 가능성도 있는가?

이 질문에 답하려면 $\hat{\beta}$ 가 표본마다 얼마나 흔들리는지 알아야 합니다. 그런데 흔들림의 크기를 계산하려면 **오차항의 행동 방식에 대한 가정**이 필요합니다. 그 가정이 바로 다음 식입니다.

$$u_i \sim N(0, \sigma^2)$$

읽는 법: “오차항 u_i 는 평균이 0이고 분산이 σ^2 인 정규분포를 따른다” (N 은 Normal의 N).

이 짧은 식에 세 가지 주장이 들어 있습니다.

부분	주장	의미
N	정규분포	오차는 종 모양으로 흩어진다
0	$E(u_i) = 0$	체계적으로 위나 아래로 치우치지 않는다
σ^2	$\text{Var}(u_i) = \sigma^2$ (모든 i 에 동일)	X 가 얼마든 흩어진 정도는 똑같다 = 동분산

동분산(homoscedasticity) — 9쪽 그림

9쪽 그림에서 각 X 위에 세로로 그려진 점들의 길이가 전부 비슷하다는 점만 보시면 됩니다.

- 동분산: $\text{Var}(Y | X) = \sigma^2$ — 소득이 80원이든 260원이든 소비가 흩어진 폭이 같다.
- 이분산(반대말): $\text{Var}(Y | X_i) = \sigma_i^2$ — 소득이 높을수록 더 넓게 흩어진다. (현실에선 흔함)

동분산은 “가정”입니다. 참이라고 증명된 게 아니라, 계산을 위해 그렇다고 치는 것입니다. 이 가정이 깨지면 어떻게 되는지가 보통 다음 강의들의 주제가 됩니다.

8. 중심극한정리(CLT) — 왜 하필 정규분포인가 (교재 9–13쪽)

CLT 한 줄 요약

원래 분포가 어떻게 생겼든, 여러 개를 더하거나 평균 내면 그 결과는 종 모양(정규분포)에 가까워진다.

표본평균에 대해 정확히 쓰면 다음과 같습니다.

$$\bar{X} \xrightarrow{n \rightarrow \infty} N\left(\mu, \frac{\sigma^2}{n}\right), \quad \text{표준오차} = \frac{\sigma}{\sqrt{n}}$$

교재 11–13쪽 그림이 그 증거입니다. $U(0, 1)$ 균등분포(완전히 평평한 네모 분포)에서 시작하는데, 이론값 $\mu = 1/2$, $\sigma^2 = 1/12$ 입니다.

n (뽑는 개수)	결과 모양	표본평균의 표준편차	이론값 $\sigma/\sqrt{n}$
1	네모 (평평)	—	0.2887

n (뽑는 개수)	결과 모양	표본평균의 표준편차	이론값 $\sigma/\sqrt{n}$
2	삼각형	0.2070	0.2041
3	모서리가 둥글어짐	0.1701	0.1667
100	거의 완벽한 종 모양	0.0286	0.0289
500	완벽한 종 모양, 매우 좁음	0.0126	0.0129

두 가지가 동시에 일어나는 걸 확인하세요.

1. 모양이 종 모양으로 바뀐다.
2. 폭이 좁아진다 ($0.207 \rightarrow 0.0126$). 표본이 클수록 추정이 정밀해진다는 뜻입니다.

폭이 좁아지는 속도에도 규칙이 있습니다. 표준오차가 $\sigma/\sqrt{n}$ 이므로 $\sqrt{n}$ 에 반비례합니다. 정밀도를 2배로 높이려면 표본을 2배가 아니라 4배로 늘려야 한다는 뜻입니다.

회귀분석에서 CLT가 두 번 쓰이는 이유 (10쪽 박스)

교재 10쪽 박스가 어려운 이유는 서로 다른 두 층위의 이야기를 나란히 놓았기 때문입니다.

① 개별 관측치 차원 — 오차항 u_i 가 정규분포인 이유

앞서 오차항은 “소득 말고 소비에 영향을 주는 온갖 자잘한 요인들의 합”이라고 했습니다.

$$u_i = \sum_{j=1}^m e_{ij} \quad (\text{수많은 미세 요인의 합})$$

합이니까 CLT가 적용됩니다. m 이 충분히 크면 $u_i \sim N(0, \sigma^2)$ 이 됩니다.

② 표본 데이터 차원 — $\hat{\beta}$ 가 정규분포인 이유

앞서 L(Linear)에서 $\hat{\beta} = \sum w_i Y_i$ 라고 했습니다. 역시 합입니다. 따라서 표본 크기 n 이 충분히 크면, **설령 u_i 가 정규분포가 아니더라도**

$$\hat{\beta} \xrightarrow{n \rightarrow \infty} N(\beta, \sigma_{\hat{\beta}}^2)$$

가 성립합니다.

이 ②가 실무적으로 대단히 중요합니다. 현실 데이터의 오차가 정규분포가 아니어도, 표본만 충분히 크면 t 검정과 F 검정을 그대로 쓸 수 있다는 면죄부이기 때문입니다.

(참고: 교재 10쪽에 “CTL”이라고 적힌 곳은 CLT의 오타입니다.)

9. $\hat{\beta}$ 의 분포와 표준오차 (교재 14쪽)

$$\hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$$

읽는 법: “ $\hat{\beta}$ 는 참값 β 를 중심으로, $\sigma_{\hat{\beta}}^2$ 만큼의 폭으로 흩어지는 정규분포를 따른다”

- 중심이 β 라는 것 $\rightarrow$ 불편성(Unbiased)

- 폭 σ_{β}^2 가 줄수록 좋다는 것 → **Best**

즉 14쪽 식 하나에 BLUE의 U와 B가 요약되어 있습니다. 분산의 구체적 형태는 다음과 같습니다.

$$\sigma_{\beta}^2 = \frac{\sigma^2}{\sum_i (X_i - \bar{X})^2} \quad \sigma_{\alpha}^2 = \sigma^2 \frac{\sum_i X_i^2}{n \sum_i (X_i - \bar{X})^2}$$

왼쪽이 **기울기**, 오른쪽이 **절편**의 분산입니다. (교재 14쪽에 실린 식은 오른쪽, 즉 절편 쪽 공식입니다. 자세한 내용은 15절 참고.)

이 식에서 바로 읽어낼 수 있는 사실이 하나 있습니다. 분모의 $\sum (X_i - \bar{X})^2$ 이 클수록, 즉 X 가 **넓게 퍼져 있을수록** 추정이 **정밀해집니다**. 소득이 80-260원까지 골고루 퍼진 데이터가, 100-120원에만 몰린 데이터보다 훨씬 좋은 추정을 준다는 뜻입니다.

표준오차(standard error)의 정체

$se(\hat{\beta}) = \sqrt{\sigma_{\beta}^2}$ 를 **표준오차**라고 부르고, 회귀 결과표의 std err 열에 나오는 값입니다.

표준오차 = “표본을 다시 뽑는다면 $\hat{\beta}$ 가 이 정도는 흔들리겠구나”의 크기

교재 예에서 소득 계수의 표준오차는 0.025입니다. $\hat{\beta} = 0.6$ 이므로, 표본을 다시 뽑으면 대략 0.575 ~ 0.625 범위에서 놀 것이라고 예상할 수 있습니다.

68-95-99.7 규칙 (14쪽 하단)

정규분포에서는 중심으로부터 $\pm 1\sigma$ 안에 약 **68%**, $\pm 2\sigma$ 안에 약 **95%**, $\pm 3\sigma$ 안에 약 **99.7%**가 들어 있습니다. 여기서 95% 신뢰구간의 실무 공식이 나옵니다.

$$\hat{\beta} \pm 2 se(\hat{\beta}) = 0.6 \pm 2(0.025) = [0.55, 0.65]$$

→ “진짜 β 는 0.55와 0.65 사이일 것이라고 95% 정도 확신한다.”

이 구간에 0이 들어 있지 않다는 점을 기억하세요. 뒤에 나올 “유의하다”는 판정과 정확히 같은 이야기입니다.

왜 t 분포가 등장하는가

한 가지 문제가 있습니다. 모집단 오차의 분산 σ^2 을 모른다는 것입니다. 그래서 표본의 잔차로 계산한 $\hat{\sigma}^2$ 을 대신 씁니다.

추측한 값($\hat{\sigma}^2$)을 써서 또 추측하니 불확실성이 이중으로 쌓입니다. 그래서 정규분포보다 꼬리가 두툼하고 퍼진 t 분포를 씁니다.

$$\frac{\hat{\beta} - \beta}{se(\hat{\beta})} \sim t_{(n-2)}$$

자유도 $n-2$ 는 계수를 두 개($\hat{\alpha}, \hat{\beta}$) 추정하느라 정보를 두 칸 썼다는 뜻입니다. 표본이 커지면 t 분포는 표준정규분포 $N(0, 1)$ 과 거의 같아집니다.

실무 감각: n 이 30을 넘어가면 t 분포와 정규분포는 거의 구별되지 않습니다.

10. 가설검정 (교재 15-17쪽)

무죄추정의 원칙 — 이 비유 하나면 충분합니다

재판	통계
피고인은 무죄로 추정	귀무가설 H_0 (“관계 없다”)를 일단 참으로 둔다
검사가 유죄 증거 제시	연구자가 데이터를 제시
증거가 합리적 의심을 넘어설 만큼 강하면	데이터가 H_0 아래에서 나오기 너무 희박하면
유죄 판결	H_0 기각 → 대립가설 채택
증거 부족 → 무죄 (결백 증명이 아님)	기각 실패 → “관계 없음이 증명된 것이 아니라, 있다고 말할 증거가 부족한 것”

마지막 줄이 시험과 논문에서 가장 자주 틀리는 부분입니다. “기각하지 못했다”는 “ H_0 가 참이다”가 아닙니다.

가설 세우는 방향에 주의

교재가 강조하듯, 귀무가설에는 연구자가 주장하고 싶은 것의 반대를 넣습니다.

$$H_0 : \beta = 0 \quad (\text{영향이 없다}) \qquad H_1 : \beta \neq 0 \quad (\text{내 주장})$$

왜 이렇게 뒤집을까요? 보수적으로 접근하기 위해서입니다. 내 주장을 기본값으로 두면 확증편향에 빠지기 쉽지만, 반대를 기본값으로 두고 그걸 뒤엎을 만큼 증거가 강할 때만 내 주장을 받아들이면 훨씬 엄격한 검증이 됩니다.

검정 3단계 (16쪽)

1. H_0 와 H_1 을 정한다. 예: $H_0 : \beta = 0.8$, $H_1 : \beta \neq 0.8$
2. H_0 가 참이라고 가정하고 $\hat{\beta}$ 의 분포를 그린다. → 0.8을 중심으로 한 종 모양
3. 내가 실제로 얻은 $\hat{\beta} = 0.86$ 이 그 분포에서 얼마나 희귀한 값인지 본다.

교재 그림에서 0.86 오른쪽 빗금 면적이 7%라면, 이 7%가 p 값입니다. 기호로 쓰면

$$p = P(\hat{\beta} \geq 0.86 \mid H_0 \text{ 참}) = 0.07$$

11. p 값 완전 정복 (교재 16-18쪽)

p 값의 정의

귀무가설이 참이라고 가정했을 때, 지금 내가 얻은 값(또는 그보다 더 극단적인 값)이 나올 확률.

핵심은 “귀무가설이 참이라고 가정했을 때” 라는 전제 조건입니다. p 값은 항상 H_0 세계 안에서 계산된 조건부 확률입니다.

판정 기준: 유의수준(significance level)

7%는 희귀한가요? 기준이 필요합니다. 그 기준선이 유의수준 α 이고, 보통 5%, 1%, 때로 10%를 씁니다. (여기서의 α 는 회귀식 절편의 α 와 기호만 같을 뿐 다른 개념입니다. 관례상 둘 다 α 를 씁니다.)

$$p < \alpha \Rightarrow H_0 \text{ 기각 (유의하다)} \quad p > \alpha \Rightarrow \text{기각 실패 (유의하지 않다)}$$

교재 17쪽 예로 $p = 0.07$ 일 때

- 유의수준 10% 기준: $0.07 < 0.10 \rightarrow$ 기각 (유의함)
- 유의수준 5% 기준: $0.07 > 0.05 \rightarrow$ 기각 실패 (유의하지 않음)

같은 데이터인데 기준에 따라 결론이 달라지는 게 불편하게 느껴질 수 있는데, 이건 통계학의 결함이 아니라 **얼마나 엄격하게 볼 것인가는 연구자가 미리 선언해야 할 문제**라는 뜻입니다.

실무적 해석: “틀릴 위험”

교재 18쪽의 설명이 가장 실용적입니다.

p 값 = 귀무가설을 기각했을 때(즉 “관계가 있다”고 선언했을 때) 그 선언이 틀릴 위험의 크기

- $p = 0.02 \rightarrow$ 헛다리 짚을 위험 2% $\rightarrow$ 감수할 만함
- $p = 0.12 \rightarrow$ 위험 12% $\rightarrow$ 너무 큼, 함부로 말하면 안 됨

그래서 p 값은 낮을수록 좋습니다.

※ 교재 3쪽 문장에 대한 보충

교재 3쪽에 “ p 값은 추정계수가 의미 없을 확률”이라고 되어 있습니다. 이는 직관을 잡기 위한 편의적 표현이고, 시험이나 논문 심사에서는 통하지 않을 수 있으니 아래 차이를 알아두시는 게 좋습니다.

	서술	기호
교재의 편의적 표현	계수가 의미 없을 확률	$P(H_0 \mid \text{데이터})$
엄밀한 정의	H_0 가 참일 때 이런 데이터가 나올 확률	$P(\text{데이터} \mid H_0)$

조건이 정반대로 뒤집혀 있습니다. 실무 판단에서는 결과가 대체로 같아서 교재처럼 가르치는 경우가 많지만, 학계에서 오랫동안 지적되어 온 대표적 오해이기도 합니다(Wasserstein & Lazar, 2016). “ p 값은 데이터에 대한 확률이지, 가설에 대한 확률이 아니다” 정도로 정리해 두세요.

t 통계량과 p 값의 관계

$$t = \frac{\hat{\beta} - \beta_0}{\text{se}(\hat{\beta})} \xrightarrow{H_0: \beta_0=0} t = \frac{\hat{\beta}}{\text{se}(\hat{\beta})}$$

교재 결과표로 직접 확인해 봅시다.

항목	계수	표준오차	계산	표의 t 값
절편	17	4.662	$17/4.662 = 3.647$	3.647 ✓

항목	계수	표준오차	계산	표의 t 값
소득	0.6	0.025	$0.6/0.025 = 24$	23.537 (반올림 차이)

소득의 표준오차 실제값은 0.02549... 이며, 표에 0.025로 반올림 표기되어 약간 어긋나 보입니다.

t 값의 직관: “추정치가 0에서 표준오차 몇 개만큼 떨어져 있는가”

$t = 23.5$ 는 0에서 표준오차 23개 반만큼 떨어져 있다는 뜻입니다. 정규분포에서 $\pm 3\sigma$ 밖은 0.3%밖에 안 되는데 23이라면 사실상 불가능한 거리입니다. 그래서 p 값이 0으로 표시된 것입니다.

암기용 어렵값: $|t| > 2$ 이면 대략 5% 수준에서 유의하다.

12. 회귀 결과표 전체 읽기 (교재 3쪽 표)

항목	값	읽는 법
절편 $\hat{\alpha}$	17	소득 0일 때 평균 소비
소득 계수 $\hat{\beta}$	0.6	소득 1원 증가 시 소비 평균 0.6원 증가 (가장 중요)
표준오차 $se(\hat{\beta})$	0.025	$\hat{\beta}$ 의 흔들림 폭
t 통계량	23.537	0에서 얼마나 멀리 떨어졌나
p 값	0.000	우연일 가능성 사실상 없음 → 매우 유의
R^2	0.905	소비 변동의 90.5%를 소득으로 설명
수정된 R^2	0.904	변수 개수 별점을 반영한 R^2
F 통계량	554	모형 전체가 의미 있는지
관측치 수 n	60	표본 크기

읽는 순서 (실무 팁)

1. p 값 먼저 → 이 변수 얘기를 해도 되나?
2. 계수의 부호 → 방향이 상식과 맞나? (소득 증가 → 소비 증가, 맞음)
3. 계수의 크기 → 경제적으로 의미 있는 크기인가?
4. R^2 → 모형이 전체적으로 얼마나 설명하나?

유의성(p 값)과 중요성(계수 크기)은 다른 개념입니다. 표본이 아주 크면 사실상 의미 없는 크기의 계수도 통계적으로 유의해질 수 있습니다.

알아두면 좋은 두 가지 확인 (단순회귀 한정)

설명변수가 하나뿐인 단순회귀에서는 다음 두 관계가 항상 성립합니다. 교재 숫자로 계산해 보세요.

$$F = t^2 = (23.537)^2 = 553.99 \approx 554 \quad R^2 = r_{XY}^2, \quad r_{XY} = \sqrt{0.905} \approx 0.951$$

13. R^2 의 의미 (교재 18-19쪽)

$R^2 = Y$ 의 변동 중 X 가 설명해 낸 비율 ($0 \leq R^2 \leq 1$)

$R^2 = 0.905$ 라면 “소비가 가구마다 왜 다른가”의 90.5%는 소득 차이로 설명되고, 나머지 9.5%는 다른 요인(오차항)이라는 뜻입니다.

세 개의 제곱합 (19쪽 그림)

19쪽 그림은 Y 의 흠어짐을 두 조각으로 쪼개는 그림입니다. 한 점을 놓고 보면

$$\underbrace{(Y_i - \bar{Y})}_{\text{전체 편차}} = \underbrace{(\hat{Y}_i - \bar{Y})}_{\text{회귀선이 설명한 부분}} + \underbrace{(Y_i - \hat{Y}_i)}_{\text{설명 못한 부분(잔차)}}$$

이걸 모든 점에 대해 제곱해서 더하면 다음 분해가 나옵니다.

$$\underbrace{\sum (Y_i - \bar{Y})^2}_{TSS} = \underbrace{\sum (\hat{Y}_i - \bar{Y})^2}_{ESS} + \underbrace{\sum (Y_i - \hat{Y}_i)^2}_{RSS} \implies R^2 = \frac{ESS}{TSS} = 1 - \frac{RSS}{TSS}$$

비유: 시험 점수가 학생마다 다른 이유를 100이라고 하면, 그중 90은 공부시간으로 설명되고 10은 다른 이유(컨디션, 운)라는 것. 이때 $R^2 = 0.9$.

R^2 에 대한 두 가지 주의

1. R^2 가 높다고 좋은 모형은 아닙니다. 관계없는 변수를 마구 집어넣어도 R^2 는 무조건 올라갑니다. 그래서 별점을 매긴 수정된 R^2 를 함께 봅니다.

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n - 1}{n - k - 1}$$

교재에서 $0.905 \rightarrow 0.904$ 로 살짝 낮아진 이유가 이 별점입니다.

2. R^2 가 낮다고 무의미한 모형도 아닙니다. 사회과학 데이터에서는 R^2 가 0.2-0.3만 되어도 유용한 분석인 경우가 많습니다. 교재의 0.905는 교육용으로 만든 데이터라 유난히 깔끔한 것입니다.

14. 19번 반복 실험 (교재 20-21쪽)

이 실험이 이 강의의 결론부입니다. 앞의 추상적인 개념들이 여기서 눈에 보이는 숫자로 바뀝니다.

실험 설계

- 정답: 60가구 전체(모집단)로 구한 $\beta = 0.6$
- 실험: 60가구 중 30%(18가구)를 무작위로 뽑아 회귀분석, 이를 19번 반복
- 결과: 19개의 서로 다른 $\hat{\beta}$ (최소 0.5355, 최대 0.7317)

이 결과가 증명하는 것 네 가지

관찰된 사실	대응하는 개념
매번 다른 $\hat{\beta}$ 가 나온다	표본오차(sampling error) — 표본이 달라서 생기는 오차
19개 $\hat{\beta}$ 가 하나의 분포를 이룬다	표본분포(sampling distribution) — $\hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$ 의 실물
그 분포의 중심이 0.6 근처 (평균 약 0.617)	불편성 — $E(\hat{\beta}) = \beta$
대부분 0.6 주변에 밀집	Best(최소분산) — 크게 벗어나는 경우가 드물

여기가 핵심입니다. 우리가 현실에서 하는 회귀분석은 이 19번 중 **딱 한 번**에 해당합니다. 우리가 0.5355를 뽑았는지 0.7317을 뽑았는지 알 수 없습니다. 그래서 “내 추정치가 진짜와 얼마나 다를 수 있나”를 알려주는 **표준오차**와, “0일 가능성은 없나”를 알려주는 **p값**이 반드시 함께 보고되어야 하는 것입니다.

21쪽 문장 두 가지 참고사항

- “불편이성”은 불편성(unbiasedness)의 오타로 보입니다.
- 19개 평균이 본문에는 0.6150, 그래프에는 0.6176으로 적혀 있어 살짝 다릅니다. 어느 쪽이든 “0.6에 가깝다”는 결론에는 영향이 없습니다.

15. 교재를 읽을 때 주의할 지점들

강의자료를 그대로 외웠다가 나중에 혼동할 수 있는 부분만 모았습니다.

위치	교재 표현	보충
3쪽	“p값은 추정계수가 의미 없을 확률”	직관용 표현. 엄밀히는 $P(\text{데이터} \mid H_0)$ (11절 참고)
10쪽	“CTL에 의해”	CLT (Central Limit Theorem)의 오타
14쪽	$\sigma_{\hat{\beta}}^2 = \sigma^2 \left[\frac{\sum X_i}{n \sum (X_i - \bar{X})^2} \right]$	두 가지 문제가 있습니다. ① 분자는 $\sum X_i$ 가 아니라 $\sum X_i^2$ 여야 합니다(PDF 변환 중 제곱이 누락된 것으로 보입니다). ② 이 형태는 절편 $\hat{\alpha}$의 분산 공식 입니다. 기울기 $\hat{\beta}$ 의 분산은 $\frac{\sigma^2}{\sum (X_i - \bar{X})^2}$ 로 훨씬 단순합니다.
21쪽	“불편이성”	불편성(unbiasedness)
18쪽	“ R^2 가 0.905이므로 90% 이상 설명”	맞는 해석입니다. 다만 “소득이 소비를 90% 결정한다”(인과)가 아니라 “소비의 변동 을 90% 설명한다”(통계적 설명력)입니다.

회귀분석 전체에 대한 가장 큰 오해

회귀분석은 상관관계를 보여줄 뿐, 인과관계를 증명하지 않습니다.

소득과 소비가 함께 움직인다는 것과, 소득이 소비를 일으킨다는 것은 다른 주장입니다. 이 예에서는 경제 이론상 인과 방향이 명백하지만, 일반적으로 “ X 가 Y 의 원인이다”라고 말하려면 추가적인 논거나 연구설계가 필요합니다. 이후 강의에서 다뤄질 내생성·누락변수 문제가 여기서 출발합니다.

16. 용어 사전

용어	영어	기호	한 줄 정의
회귀분석	regression analysis	—	X 와 Y 의 평균적 관계를 찾는 방법
종속변수	dependent variable	Y	설명당하는 쪽 (소비)
독립변수	independent variable	X	설명하는 쪽 (소득)
절편	intercept	α	$X = 0$ 일 때의 Y 예측값
기울기 / 계수	slope, coefficient	β	X 가 1 늘 때 Y 의 평균 변화량
오차항	error term	u_i	$Y_i - \hat{Y}_i$. 모형이 설명 못한 부분
조건부 평균	conditional mean	$E(Y X)$	X 고정 시 Y 의 평균
모집단	population	—	알고 싶은 대상 전체
표본	sample	n	실제로 조사한 일부
PRF	population regression function	$Y_i = \alpha + \beta X_i + u_i$	모집단 회귀식 (알 수 없음)
SRF	sample regression function	$\hat{Y}_i = \hat{\alpha} + \hat{\beta} X_i$	표본 회귀식 (내가 구한 것)
OLS	ordinary least squares	$\min \sum \hat{u}_i^2$	오차 제곱합 최소화로 선긋기
LAD	least absolute deviation	$\min \sum \hat{u}_i $	절댓값합 최소화. 이상치에 강함
BLUE	best linear unbiased estimator	—	선형 불편 추정량 중 분산 최소
불편성	unbiasedness	$E(\hat{\beta}) = \beta$	반복 평균 내면 참값이 됨
동분산	homoscedasticity	$\text{Var}(u_i) = \sigma^2$	X 가 얼마든 오차 흩어짐이 일정
이분산	heteroscedasticity	$\text{Var}(u_i) = \sigma_i^2$	동분산이 깨진 상태
표본오차	sampling error	—	표본이 달라서 생기는 추정치 차이

용어	영어	기호	한 줄 정의
표본분포	sampling distribution	$\hat{\beta} \sim N(\beta, \sigma_{\hat{\beta}}^2)$	추정치가 표본마다 이루는 분포
표준오차	standard error	$se(\hat{\beta})$	추정치의 흔들림 폭
중심극한정리	central limit theorem	—	많이 더하면 정규분포에 가까워진다
귀무가설	null hypothesis	H_0	기각하려고 세우는 가설 (보통 $\beta = 0$)
대립가설	alternative hypothesis	H_1	연구자가 주장하는 내용
유의수준	significance level	α	기각 기준선 (5%, 1% 등)
p 값	p -value	$P(\text{데이터} \mid H_0)$	H_0 참일 때 이런 결과가 나올 확률
t 통계량	t -statistic	$\hat{\beta}/se(\hat{\beta})$	0에서 표준오차 몇 개만큼 떨어졌나
결정계수	R-squared	$R^2 = ESS/TSS$	Y 변동 중 X 가 설명한 비율
제곱합 분해	sum of squares	$TSS = ESS + RSS$	전체 = 설명된 + 남은

17. 한 장 요약 (시험 전날용)

[1] 목적 — X 와 Y 의 평균적 관계를 β 로 표현한다. 회귀선은 X 를 고정했을 때 Y 의 조건부 평균들을 이은 선이다.

$$E(Y \mid X_i) = \alpha + \beta X_i$$

[2] 문제 — 진짜 β (모집단)는 알 수 없다. 표본으로 $\hat{\beta}$ 를 구해 추정한다.

$$\text{PRF: } Y_i = \alpha + \beta X_i + u_i \quad \longrightarrow \quad \text{SRF: } \hat{Y}_i = \hat{\alpha} + \hat{\beta} X_i$$

[3] 방법 — OLS는 오차제곱합을 최소화한다. 그 결과 $\hat{\beta}$ 는 BLUE(불편 + 최소분산 + 선형)가 된다.

$$\min \sum (Y_i - \hat{\alpha} - \hat{\beta} X_i)^2$$

[4] 신뢰성 판단 — $\hat{\beta}$ 는 표본마다 흔들리지만 중심은 β 다. 근거는 오차항 정규성·동분산 가정과 CLT이며, 도구는 표준오차와 t 값이다.

$$\hat{\beta} \sim N\left(\beta, \sigma_{\hat{\beta}}^2\right), \quad \sigma_{\hat{\beta}}^2 = \frac{\sigma^2}{\sum (X_i - \bar{X})^2}, \quad t = \frac{\hat{\beta}}{se(\hat{\beta})}$$

[5] 판정 — p 값과 유의수준을 비교한다. 모형 전체의 설명력은 R^2 로 본다.

$$p < 0.05 \Rightarrow H_0 \text{ 기각 (유의)} \quad |t| > 2 \Rightarrow \text{대략 같은 결론} \quad R^2 = \frac{ESS}{TSS}$$

[6] 이 예의 결론

$$\hat{Y} = 17 + 0.6X, \quad t = 23.5, \quad p \approx 0, \quad R^2 = 0.905$$

소득이 1원 늘면 소비는 평균 0.6원 늘고, 이 결과가 우연일 가능성은 사실상 없으며, 소비 변동의 90.5%가 소득으로 설명된다.

참고문헌

- Gujarati, D. N., & Porter, D. C. (2009). *Basic econometrics* (5th ed.). McGraw-Hill/Irwin.
- Stock, J. H., & Watson, M. W. (2019). *Introduction to econometrics* (4th ed.). Pearson.
- Wasserstein, R. L., & Lazar, N. A. (2016). The ASA statement on p-values: Context, process, and purpose. *The American Statistician*, 70(2), 129–133. <https://doi.org/10.1080/00031305.2016.1154108>
- Wooldridge, J. M. (2020). *Introductory econometrics: A modern approach* (7th ed.). Cengage Learning.
- 제1강 회귀분석(regression analysis)이란? [강의자료]. (n.d.). 미간행 강의자료.

주석: 본 해설서의 모든 수치와 그림 설명은 업로드된 강의자료 『제1강 회귀분석이란?』(1–23쪽)에서 가져왔습니다. BLUE와 가우스-마르코프 정리, PRF/SRF 구분, $TSS = ESS + RSS$ 분해의 표준적 정의, 그리고 강의자료 6쪽·14쪽·19쪽 그림의 원출처는 Gujarati와 Porter(2009)의 서술 체계를 따릅니다. 계수 분산 공식 $\sigma_{\hat{\beta}}^2 = \sigma^2 / \sum (X_i - \bar{X})^2$ 및 절편 분산 공식의 표기도 같은 문헌을 따랐습니다. 중심극한정리의 회귀분석 적용과 표본이 클 때 오차항 정규성 가정을 완화할 수 있다는 논의는 Wooldridge(2020)와 Stock 및 Watson(2019)에서 표준적으로 다루집니다. 11절의 p 값 해석에 관한 보충은 Wasserstein과 Lazar(2016)의 미국통계학회 성명에 근거합니다.